LOUISIANA, 2016

Identificação de imagens alagadas

Cor, textura e aprendizado de máquina

Random Forest

Henrique Freitas e Guilherme Menna



O problema é classificar cada imagem

0 Não alagada



1 Alagada



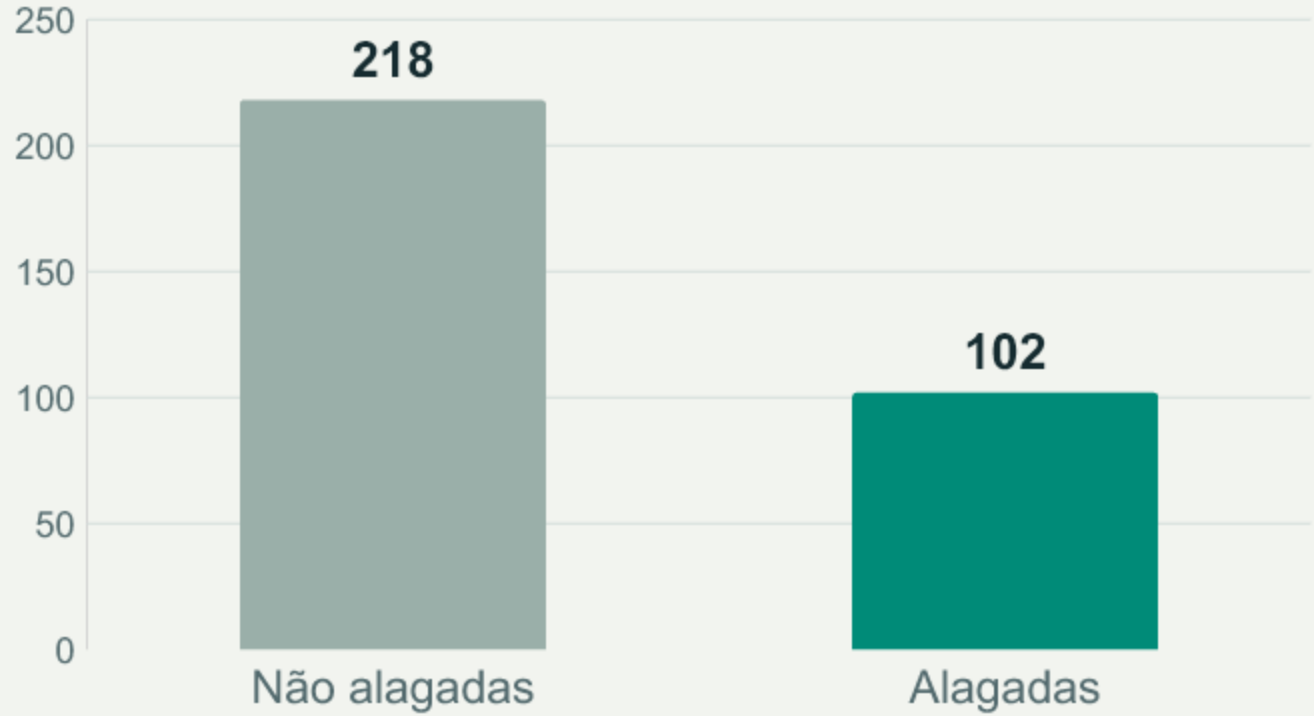
A análise usa imagens já capturadas e atribui um rótulo à imagem inteira.

Uma base pequena e desbalanceada

320

imagens após a limpeza

512 × 360 pixels
Imagens RGB



A classe alagada representa 31,9% da base corrigida.

Duas cópias poderiam contaminar o teste

322

imagens originais

320

imagens após remover o par do treino

SHA-256 identifica arquivos idênticos mesmo quando os nomes são diferentes.

Teste preservado
Zero imagens ilegíveis
Sem valores faltantes

Cada imagem vira 45 atributos numéricos



RGB em 128 × 128 pixels
Intensidades entre 0 e 1

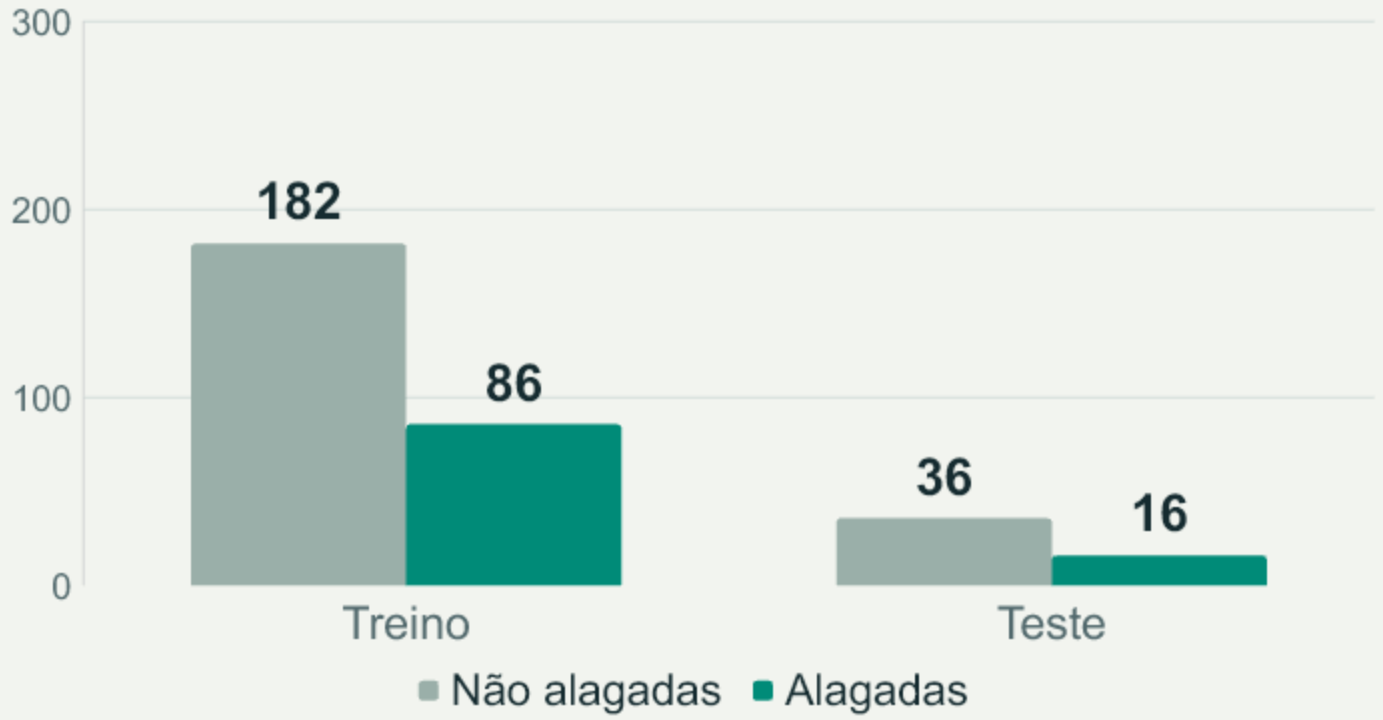
12 Estatísticas de cor RGB

06 Matiz, saturação e brilho

24 Histogramas RGB

03 Medidas de textura

Treino e teste ficam separados por cena



268 imagens de treino
134 cenas

52 imagens de teste
26 cenas

Zero cenas ou arquivos idênticos compartilhados entre os conjuntos.

O modelo combina 200 árvores

Random Forest

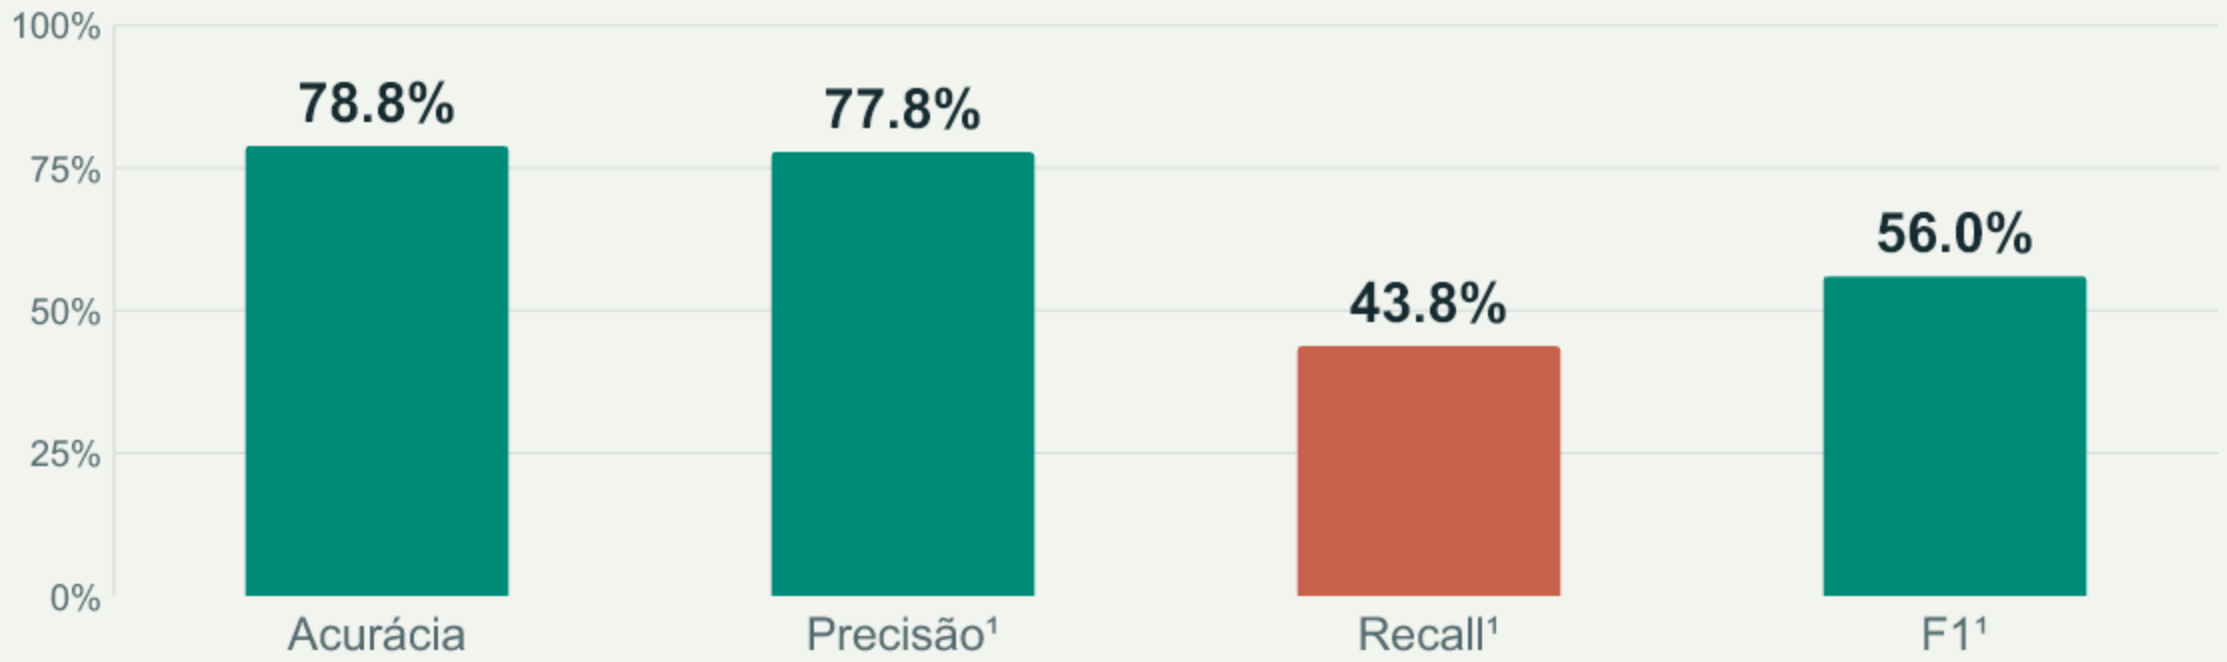
Profundidade máxima 10
Semente aleatória 42

StandardScaler ajustado no treino
Pipeline com parâmetros fixos



Entrada: atributos visuais
Saída: classe 0 ou 1

78,8% de acurácia no conjunto de teste



41 acertos em 52 imagens

F1 macro: 0,710

¹ Métricas da classe alagada. Resultados da execução salva no notebook.

O modelo deixou passar 9 alagamentos

	CLASSE PREVISTA	
Classe real	Não alagada	Alagada
Não alagada	**34**	**2**
Alagada	**9**	**7**

7 de 16

alagamentos identificados

2 falsos positivos
9 falsos negativos

Mais da metade das imagens alagadas recebeu a classe “não alagada”.

A acurácia isolada esconde a dificuldade

69,2%

se todas as previsões fossem
“não alagada”

78,8%

acurácia observada
no Random Forest

O ganho global é de 9,6 pontos percentuais,
mas o recall de alagamento ainda é 43,75%.

Limites do experimento

Um único evento

A base pequena limita o que podemos afirmar sobre outras regiões e datas.

Cor e textura resumem a imagem

Histogramas perdem posição e forma.
A média de matiz é uma aproximação.



Proximidade geográfica entre cenas ainda não foi verificada.

Conclusão e próximos passos

O fluxo funciona.
A detecção precisa melhorar.

Mais cenas e eventos

Avaliar a generalização em dados independentes.

Maior atenção aos falsos negativos

Comparar melhorias usando validação e preservar o teste final.

Fontes e créditos

Henrique Freitas e Guilherme Menna

Código e resultados

menagui / LouisianaFloodsChalleng

Dataset e imagens

Louisiana flood 2016 · Rahul T P · Kaggle

Versão 4. Fontes originais citadas: NOAA e LouisianaView.

Disciplina de Inteligência Artificial e Aprendizado de Máquina
Professor Flávio · 1º semestre de 2026